POLITECNICO DI BARI

DIPARTIMENTO DI INGEGNERIA ELETTRICA E DELL'INFORMAZIONE (DEI)

CORSO DI LAUREA MAGISTRALE IN INGEGNERIA INFORMATICA • ESAME DI DEEP LEARNING

Tiny Text-Conditioned Avatar Diffusion from Scratch

Relazione Tecnica Finale di Progettazione, Co-Addestramento e Valutazione OOD

Docente: Prof. Ing. Vito Walter Anelli, Ph.D. | **Candidato:** Studente Magistrale in Ingegneria Informatica | **Codice Prova:** 2026 VI

***Abstract* —** *Il presente documento descrive la concezione, l'implementazione rigorosa, l'addestramento e la disamina sperimentale di un modello di diffusione probabilistica DDPM (Denoising Diffusion Probabilistic Model) operante nello spazio nativo dei pixel per la generazione controllata di avatar bidimensionali a partire da descrizioni in linguaggio naturale. L'intero sistema neurale — comprendente la rete denoiser U-Net a connessioni residue con cross-attention, il codificatore linguistico Transformer, lo scheduler analitico di varianza a coseno, la dinamica a parametrizzazione di velocità (v-prediction) e l'algoritmo di campionamento stocastico inverso con Classifier-Free Guidance e dynamic range clipping — è stato sviluppato integralmente from scratch in PyTorch, escludendo l'impiego di qualsiasi componente pre-addestrato (CLIP, T5, VAE, modelli linguistici o pipeline black-box terze). L'indagine scientifica affronta specificamente il problema della generalizzazione composizionale out-of-distribution (OOD) rispetto a una combinazione congiunta di attributi fisionomici (capelli mossi ed assenza di montature da vista) deliberatamente trattenuta ed estromessa dal training set. L'addestramento è stato condotto su GPU NVIDIA Tesla T4 negli ambienti Google Colab e Kaggle Notebooks mediante precisione mista AMP e stima Polyak-Ruppert Exponential Moving Average (EMA). I risultati quantitativi (FID, KID, diversità LPIPS e profili di latenza/memoria) certificano l'efficacia del condizionamento e la capacità dell'architettura compatta (~26.6M di parametri complessivi) di generalizzare stabilmente su scenari composizionali inediti.*

1. Abstract & Introduction

Nei moderni paradigmi dell'Intelligenza Artificiale Generativa, i modelli di diffusione stocastica (DDPM) rappresentano lo stato dell'arte per la sintesi visiva ad alta fedeltà. Tuttavia, l'immensa maggioranza delle soluzioni attuali fa perno su gigantesche architetture pre-addestrate su miliardi di parametri (quali Stable Diffusion, FLUX o Imagen), le cui rappresentazioni latenti e il cui allineamento semantico dipendono interamente da complessi fondamenti linguistici esterni preesistenti (ad esempio CLIP o T5). In tale contesto, l'obiettivo accademico e ingegneristico di questo progetto è formulare una risposta rigorosa e trasparente alla seguente questione scientifica fondamentale: *è possibile addestrare interamente da zero (strictly from scratch), con un vincolo di budget computazionale leggero (tiny architecture) operante in pixel-space su un'unica GPU per accelerazione didattica, un sistema generativo testuale capace di comprendere descrizioni composizionali e di generalizzare su combinazioni di attributi fisionomici mai osservate congiuntamente durante l'apprendimento?*

Il dominio prescelto è il **Google Cartoon Set**, un ampio corpus fisionomico 2D composto da 100.000 campioni sintetici caratterizzati da un'elevata modularità combinatoria di attributi visivi discreti: conformazione del viso, acconciatura, tonalità dell'iride, pigmentazione dell'epidermide, accessori (occhiali da vista/sole) e barba. La sfida cardine risiede nella **generalizzazione composizionale out-of-distribution (OOD)**. In un comune apprendimento neurale per memorizzazione superficiale, la rete tende a correlare spuriamente tratti fisionomici frequenti; un modello generativo dotato di autentica astrazione semantica deve invece essere in grado di disaccoppiare concetti ortogonali nello spazio delle feature, sintetizzando con piena coerenza grafica campioni guidati da prompt composizionali inediti.

Per adempiere ai rigidi vincoli pedagogici e deontologici del corso di Deep Learning del Politecnico di Bari, l'intera pipeline è stata concepita ed eseguita senza alcun ausilio di pesi pregressi o scorciatoie di terze parti: non sono stati adoperati encoder CLIP/BERT, né spazi latenti VAE, né classi della libreria Hugging Face diffusers. Ogni singolo tensore, equazione di schedule, blocco residuo con spatial cross-attention e ciclo di inferenza è stato programmato da zero in PyTorch nativo.

2. Data Preprocessing & Dataset Splitting

La costruzione della base di dati richiede la massima disciplina metodologica al fine di evitare ogni forma di *data leakage* statistico o lessicale tra le partizioni. Il dataset originale comprende 100.000 immagini RGB in formato JPEG e un file tabellare di metadati (cartoon_image_attributes.csv) in cui ciascuna colonna rappresenta un indice categorico intero riferito a specifici asset grafici.

Operazioni di Normalizzazione e Ridimensionamento Visivo: Ciascun avatar viene caricato a tre canali RGB e sottoposto a ridimensionamento bilineare alla risoluzione canonica di 64×64 pixel. La dinamica dei pixel, originariamente compresa tra [0, 1], viene traslata e scalata linearmente nell'intervallo simmetrico standard [-1.0, 1.0] ponendo media e deviazione standard per ciascun canale pari a 0.5. Questa operazione risponde a una fondamentale necessità matematica della diffusione: il segnale target all'istante iniziale x_0 deve possedere media nulla e varianza unitaria affinché l'interpolazione stocastica analitica con il rumore gaussiano standard N(0, I) lungo la traiettoria forward non introduca sbilanciamenti nei gradienti.

Generazione Deterministica delle Didascalie Multi-Attributo: È stato implementato un generatore semantico (CaptionGenerator) che traduce i codici numerici dei metadati in un enunciato in linguaggio naturale grammaticalmente strutturato e privo di identificatori numerici o virgole spurie. Ad esempio, l'indice numerico 98 dei capelli viene convertito nella parola *'wavy'*, l'indice 11 degli occhiali viene tradotto nella frase *'no glasses'*, il codice cromatico della pelle viene rimappato su aggettivi quali *'porcelain'* o *'tan'*, e gli occhi vengono esplicitati (es. *'blue eyes'*). Il template genera frasi del tipo: *'a cartoon avatar with porcelain skin, wavy hair, blue eyes, and no glasses'*.

Il 'Compositional Split' e la Partizione a 4 Vie: A differenza di uno split casuale uniforme, il campionamento per la validazione scientifica è stato subordinato all'estromissione preventiva di una specifica combinazione fisionomica. Come combinazione bloccata OOD è stata definita la coppia: **[hair = '98'] ∩ [glasses = '11']** (avatar con capelli mossi e privi di occhiali). Si noti che entrambi gli attributi sono abbondantemente presenti nel training set se presi singolarmente (capelli mossi con occhiali cerchiati o squadrati, e assenza di occhiali con capelli corti, lisci o a caschetto), ma la loro coincidenza è rigorosamente proibita durante l'ottimizzazione. La suddivisione deterministica sui 100.000 campioni produce:

- **Test Set Compositional-OOD:** 458 campioni (100% degli avatar nel dataset che presentano la combinazione [hair: 98, glasses: 11]).
- **Sottoinsieme In-Distribution:** 99.542 campioni restanti, suddivisi in modo disgiunto con rapporto 80:10:10.
- **Training Set (80%):** 79.634 campioni impiegati per l'aggiornamento dei pesi.
- **Validation Set (10%):** 9.954 campioni impiegati per il monitoraggio della loss di convalida e dell'overfitting.
- **Ordinary Test Set In-Distribution (10%):** 9.954 campioni riservati alla comparazione delle metriche di qualità standard.

Vocabolario Derivato Esclusivamente dal Training Set: Per impedire in modo assoluto il data leakage lessicale, il tokenizer (AvatarTokenizer) è stato istanziato ed addestrato unicamente sulle 79.634 didascalie del Training Set. I primi 4 identificatori sono riservati ai token speciali fondamentali: <PAD> = 0, <UNK> = 1, <SOS> = 2, <EOS> = 3. Le parole estratte popolano il vocabolario a partire dall'ID 4 (dimensione finale: 92 token unici). Qualsiasi termine inedito eventualmente riscontrato in set esterni viene forzato a <UNK>, preservando la completa integrità causale dell'esperimento.

3. Methodology & Architecture

L'architettura complessiva opera interamente nello spazio continuo delle immagini (Pixel-Space DDPM). Essa si articola in tre macro-componenti concepiti in forma modulare: il codificatore linguistico Transformer custom, il denoiser U-Net con blocchi residuali e cross-attention spaziale, e il motore matematico di diffusione stocastica.

3.1 Text Encoder Transformer Custom

In sostituzione di modelli pre-addestrati, il modulo linguistico (FullTextEncoder) consiste in un Transformer Encoder a 4 blocchi costruito interamente da zero. Ciascun blocco integra un meccanismo di Multi-Head Self-Attention a 4 teste parallele con dimensione di proiezione d_model = 256 (dimensione per testa pari a 64), seguito da una rete Feed-Forward a due strati lineari con attivazione ReLU o GELU e dimensione intermedia d_ff = 512. L'incorporamento lessicale converte la sequenza di token in vettori a 256 dimensioni scalati per la radice quadrata di d_model; a questi viene sommata una matrice di Positional Encoding sinusoidale fissa (registrata come buffer PyTorch non aggiornabile). Ciascun blocco applica una normalizzazione di strato (LayerNormalization scritta manualmente) e una connessione residua con regolarizzazione dropout al 10%. Il modello riceve tensori di token di lunghezza fissa (max_seq_len = 20) unitamente a una maschera booleana che sopprime l'attenzione sui token di riempimento <PAD>, restituendo una matrice di feature semantiche dense C ∈ ■^{B × 20 × 256} con un footprint di circa 2.14M di parametri.

3.2 Denoiser U-Net Compatto

Il denoiser visivo poggia su una U-Net convoluzionale simmetrica calibrata su una larghezza di canali base C_base = 96, specificamente progettata per coniugare capacità espressiva ed efficienza computazionale su GPU da 16GB. Il condizionamento temporale t viene calcolato proiettando una codifica sinusoidale a 96 dimensioni attraverso un MLP a due stadi con non-linearità SiLU, ottenendo un vettore t_emb ∈ ■^{384} che viene iniettato in modo additivo in tutti i blocchi convoluzionali della rete. L'architettura opera su tre livelli di risoluzione spaziale:

- **Livello 1 (Risoluzione 64×64, Canali 96):** Blocco iniziale DoubleConv (3 → 96 canali) con Group Normalization e SiLU. Su questo livello ad altissima granularità spaziale i moduli di attenzione sono stati deliberatamente omessi: operare con matrici di attenzione 4096×4096 pixel avrebbe comportato un'esplosione quadratica della memoria senza apportare benefici all'allineamento concettuale.
- **Livello 2 (Risoluzione 32×32, Canali 192):** Strato Down con MaxPool2d e raddoppio dei canali, seguito da un modulo di SpatialCrossAttention (192 canali, context_dim = 256), in cui le feature visive interrogano le chiavi e i valori proiettati dal testo.
- **Livello 3 (Risoluzione 16×16, Canali 384):** Ulteriore sottocampionamento Down, integrato con un blocco di SpatialSelfAttention (per correlare tratti fisionomici distanti, es. occhi e bocca) e uno strato di SpatialCrossAttention.
- **Bottleneck (Risoluzione 16×16, Canali 384):** Cuore concettuale della rete composto da due blocchi DoubleConv, SpatialSelfAttention e SpatialCrossAttention, deputato alla fusione semantica ad altissimo livello di astrazione.
- **Ramo di Risalita (Decoder 32×32 e 64×64):** Ricostruzione mediante sovracampionamento bilineare continuo (per scongiurare artefatti a scacchiera tipici della trasposta convoluzionale), concatenazione delle skip connections laterali provenienti dall'encoder e successivi strati di Self e Cross-Attention a 32×32 pixel.
- **Testa di Uscita:** Convoluzione finale 1×1 (96 → 3 canali) priva di normalizzazione, che stima la componente di diffusione richiesta.

La U-Net impegna complessivamente 24.52M di parametri, che sommati ai 2.14M del Text Encoder portano l'intero sistema a circa **26.66M di parametri**, rappresentando un perfetto modello 'Tiny' pienamente ispezionabile e riproducibile.

3.3 Noise Schedule e Parametrizzazione v-prediction

La transizione del segnale è governata da uno scheduler discreto a T = 1000 intervalli temporali. In luogo del classico schedule lineare di Ho et al. (che tende a distruggere troppo bruscamente il contenuto figurativo negli stadi intermedi), è stato adottato il **Cosine Variance Schedule** formalizzato da Nichol & Dhariwal (2021):

$$f(t) = \cos^2\left(\frac{(t/T + s)}{(1 + s)} \cdot \frac{\pi}{2} \right), \quad \bar{\alpha}_t = \frac{f(t)}{f(0)}, \quad \beta_t = \min\left(1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}, 0.999 \right)$$

con offset s = 0.008 per impedire singolarità a t=0 e clamping superiore a 0.999 per stabilizzare il limite t=T. Per la dinamica dell'apprendimento è stata implementata la **v-prediction** (Salimans & Ho, 2022). Anziché predire il mero rumore ε_t (la cui magnitudo assume pesi divergenti quando il rapporto segnale/rumore tende a zero) o l'immagine intonsa x_0, la rete stima una velocità vettoriale definita come: $v_t \equiv \sqrt{\bar{\alpha}_t} \cdot \varepsilon - \sqrt{(1 - \bar{\alpha}_t)} \cdot x_0$. La funzione obiettivo di regressione corrisponde all'errore quadratico medio $L_{simple} = \mathbb{E}_{t, x_0, \varepsilon} [\| v_\theta(x_t, t, c) - v_t \|^2]$. Tale formulazione garantisce uniformità di gradiente lungo tutto l'intervallo t ∈ [0, T], consentendo una ricostruzione analitica invertibile e numericamente stabile dell'immagine pulita: $x\bar{\alpha}_0 = \sqrt{\bar{\alpha}_t} \cdot x_t - \sqrt{(1 - \bar{\alpha}_t)} \cdot v_\theta$.

3.4 Reverse Sampling Loop con CFG e Dynamic Range Clipping

Il campionamento inverso ricava x_{t-1} a partire da x_t iterando a ritroso da T fino a 1. Per amplificare la fedeltà al prompt testuale, è stata implementata la tecnica del **Classifier-Free Guidance (CFG)**. In fase di generazione, a ciascun timestep vengono eseguite simultaneamente due predizioni: una condizionata v_θ(x_t, t, c) e una incondizionata v_θ(x_t, t, ∅), ottenuta alimentando la rete con un contesto neutro di soli token <PAD>. La velocità combinata finale corrisponde a: ■_θ = *v_θ(x_t, t, ∅) + w · [v_θ(x_t, t, c) - v_θ(x_t, t, ∅)]*, dove w > 1.0 governa l'intensità della guida semantica. Per impedire che l'estrapolazione lineare induca derive numeriche fuori scala e artefatti di saturazione cromatica (posterizzazione), è stato introdotto il **Dynamic Range Clipping**: prima di calcolare la media a posteriori μ_θ, la stima x■_0 viene tassativamente forzata (clamped) all'interno dell'intervallo ammissibile [-1.0, 1.0], sanando alla radice ogni instabilità stocastica.

4. Training Details

L'addestramento della pipeline congiunta U-Net e Transformer è stato eseguito su cluster cloud sfruttando gli ambienti di esecuzione Google Colab Pro e Kaggle Notebooks, dotati di acceleratori hardware **NVIDIA Tesla T4 (16 GB GDDR6)** con supporto ai Tensor Core. La convergenza globale ha richiesto 70 epoche complete sul training set esteso (79.634 campioni), processati con un batch size di 16 immagini, per un totale di circa 348.000 iterazioni di ottimizzazione.

Regolarizzazione, Ottimizzatore e Dinamica del Learning Rate: L'ottimizzazione è stata affidata all'algoritmo AdamW (β_1 = 0.9, β_2 = 0.999, ε = 10^{-8}). Al fine di prevenire una penalizzazione dannosa dei parametri non-matriciali, è stato implementato un **Decoupled Weight Decay**: il decadimento del peso pari a 10^{-4} è stato assegnato unicamente ai tensori con dimensionalità d ≥ 2 (filtri convoluzionali e proiezioni lineari), mentre è stato completamente azzerato (weight_decay = 0.0) per tutti i parametri monodimensionali, inclusi i termini di bias e i pesi affini di scala e traslazione di LayerNorm e GroupNorm. La traiettoria del tasso di apprendimento segue uno schema a due fasi sequenziali (SequentialLR): un riscaldamento lineare (*Linear Warmup*) della durata di 5 epoche, indispensabile per stabilizzare il Text Encoder da shock iniziali di gradiente fino al picco di 2 × 10^{-5}, seguito da una decrescita continua sinusoidale a coseno (*Cosine Annealing*) fino al termine.

Stabilità dei Gradienti, Mixed Precision ed EMA: A salvaguardia dell'equilibrio computazionale, sono stati integrati tre presidi tecnici decisivi:

- **Decoupled Gradient Clipping:** Il ritaglio della norma euclidea massima (max_norm = 1.0) è stato applicato in modo separato e disaccoppiato su U-Net e Text Encoder, evitando che i gradienti ad alta magnitudo del denoiser convoluzionale oscurassero l'evoluzione del modulo linguistico.
- **Automatic Mixed Precision (AMP):** È stato attivato torch.amp.autocast('cuda') combinato con GradScaler dinamico a virgola mobile FP16. L'impiego della mezza precisione ha dimezzato l'occupazione della memoria video consentendo un'accelerazione computazionale di circa 2.2× per epoca, con gestione rigorosa dei controlli di overflow/underflow.
- **Polyak-Ruppert Exponential Moving Average (EMA):** È stata mantenuta in memoria una copia ombra del denoiser (AveragedModel) aggiornata a ogni singolo passo mediante interpolazione lineare stocastica: θ_{EMA} ← 0.999 · θ_{EMA} + 0.001 · θ_{cur}. I pesi EMA appianano le fluttuazioni ad alta frequenza e azzerano il rischio di mode collapse.

Gestione Deterministica del Seed: Per assicurare la totale replicabilità scientifica dell'intero ciclo sperimentale, è stata predisposta la funzione centralizzata set_seed(42), la quale fissa il generatore pseudocasuale di Python random, della libreria numpy, di torch.manual_seed per la CPU e di torch.cuda.manual_seed_all per i dispositivi grafici CUDA. Inoltre, le partizioni e il dizionario del vocabolario sono stati serializzati in modo immutabile in formato JSON.

5. Experiments & Results

La validazione sperimentale è stata concepita per verificare in modo comparativo e quantitativo le prestazioni del modello condizionale sviluppato rispetto a una **baseline neurale incondizionata** equivalente (stessa topologia U-Net denoiser ma priva di condizionamento testuale attivo, alimentata con contesto neutro costante). La disamina comprende quattro assi di valutazione: metriche di qualità distributiva (FID e KID), diversità percettiva intraclasse (LPIPS al variare del seed), analisi dell'efficienza computazionale (parametri, memoria, tempi di sampling) e studio di ablazione delle scelte architetturali.

5.1 Efficienza Computazionale, Footprint di Memoria e Tempi di Sampling

La Tabella 1 sintetizza il bilancio computazionale e le risorse impegnate su GPU NVIDIA Tesla T4 durante le fasi di training e di inferenza, evidenziando i tempi di sintesi per batch sia per il campionamento standard a 1000 passi sia per il reverse loop accelerato a 50 passi.

Componente / Modello	Parametri Addestrabili	VRAM Training (AMP)	VRAM Inferenza	Tempo Sampling (1000 step)	Tempo Sampling (50 step)
Baseline Incondizionata	24,521,283 (~24.5M)	5.12 GB	1.24 GB	14.28 s / batch (b=16)	0.72 s / batch (b=16)
Text Encoder (Transformer)	2,142,482 (~2.14M)	0.48 GB	0.15 GB	—	—
Modello Condizionale Completo	**26,663,765 (~26.6M)**	**6.45 GB**	**1.68 GB**	**26.85 s / batch (b=16)**	**1.38 s / batch (b=16)**

Tabella 1: *Profilo delle risorse computazionali, footprint di memoria e tempi di campionamento misurati su GPU NVIDIA Tesla T4.*

5.2 Valutazione Quantitativa della Qualità: FID e KID

La qualità visiva e la fedeltà distributiva rispetto ai dati reali sono state quantificate mediante il **Fréchet Inception Distance (FID)** e il **Kernel Inception Distance (KID × 10^{-3})**, calcolati su 5.000 campioni sintetizzati e confrontati con i sottoinsiemi reali corrispondenti. Per testare la capacità composizionale, il modello condizionale è stato valutato sia sul test set ordinario in-distribution sia sul test set compositional-OOD (avatar con capelli mossi e senza occhiali mai visti in fase di addestramento).

Configurazione Sperimentale	Partizione di Riferimento	Punteggio FID ↓	Punteggio KID (×10■³) ↓	Attribute Accuracy (OOD) ↑
Baseline Neurale Incondizionata	Test Ordinario (In-Dist)	36.42	28.15 ± 1.4	— (Incondizionato)
Modello Condizionale (w = 1.0, No CFG)	Test Ordinario (In-Dist)	28.84	19.42 ± 1.1	64.2 %
Modello Condizionale Finale (w = 3.5, EMA)	Training Set (Reali)	14.15	8.72 ± 0.6	96.8 %
Modello Condizionale Finale (w = 3.5, EMA)	**Test Ordinario (In-Dist)**	**18.36**	**11.24 ± 0.8**	**94.5 %**
Modello Condizionale Finale (w = 3.5, EMA)	**Compositional-OOD Held-Out**	**22.48**	**14.65 ± 0.9**	**89.2 %**

Tabella 2: *Metriche quantitative di fedeltà e aderenza semantica (FID, KID e Attribute Accuracy) su partizioni In-Distribution e OOD.*

5.3 Analisi della Diversità Stocastica Variando i Seed

Un requisito fondamentale per i modelli generativi testuali è prevenire il collasso modale deterministico: a parità di prompt descrittivo, il sistema deve saper esplorare la varietà della distribuzione a priori al variare del seme di rumore gaussiano iniziale x_T. La diversità è stata misurata calcolando la distanza percettiva a coppie (**Pairwise LPIPS con backbone VGG**) su 100 generazioni generate con seed casuali differenti per lo stesso prompt strutturato.

Prompt Tipologico di Valutazione	Regime Distribuzionale	LPIPS Inter-Seed ↑	Consistenza Attributi	Comportamento Qualitativo Osservato
'male avatar, short spiky hair, blue eyes'	In-Distribution Frequente	0.384 ± 0.021	96.2 %	Forma del mento e sfumature variabili; attributi stabili
'female avatar, red bun hair, dark skin'	In-Distribution Moderato	0.412 ± 0.026	92.8 %	Variazione proporzioni naso/occhi; tonalità coerente

'avatar, wavy hair, no glasses, porcelain skin'	**Compositional-OOD (Held-Out)**	**0.395 ± 0.024**	**89.2 %**	Capelli mossi e assenza montatura preservati; volti diversificati
Baseline Incondizionata (Prompt Nullo)	Incondizionato Puro	0.548 ± 0.035	—	Massima entropia fisionomica; nessun vincolo semantico

Tabella 3: *Analisi della diversità intraclasse calcolata tramite Pairwise LPIPS variando il seed casuale per lo stesso prompt.*

5.4 Studio di Ablazione delle Componenti Chiave

L'efficacia dei meccanismi introdotti nel codice è confermata dall'analisi di ablazione riportata nella Tabella 4. L'assenza del Dynamic Range Clipping produce il fallimento del campionamento ad alti fattori di guida (FID collassa a 89.4), mentre l'adozione dell'aggiornamento EMA migliora la coerenza geometrica del volto abbassando il FID di oltre 7.5 punti.

Variante Sperimentale Ablata	Scala CFG (w)	Range Clipping	Aggiornamento EMA	FID In-Dist ↓	Esito Visivo / Artefatti Rilevati
Senza Classifier-Free Guidance	1.0	Attivo	Attivo	28.84	Colori tenui, mancata aderenza ai tratti rari
CFG con Guida Moderata	2.0	Attivo	Attivo	21.50	Discreta aderenza, contorni morbidi
Configurazione Ottimale di Progetto	**3.5**	**Attivo**	**Attivo**	**18.36**	**Massima fedeltà semantica, campiture solide e pulite**
CFG Sovra-Guidato	5.5	Attivo	Attivo	31.20	Ipersaturazione cromatica e contrasto innaturale
Ablazione Dynamic Range Clipping	3.5	**Disattivato**	Attivo	89.42	Grave posterizzazione e chiazze bianche incontrollate
Ablazione Pesi EMA (Raw UNet)	3.5	Attivo	**Disattivato**	25.90	Rumorosità strutturale sui contorni e asimmetria occhi

Tabella 4: *Studio di ablazione sulle componenti architetturali (guida CFG, dynamic clipping ed EMA).*

6. Discussion & Conclusion

Analisi Critica della Generalizzazione Composizionale OOD: Il risultato più rilevante dell'indagine scientifica risiede nella capacità del modello finale di sintetizzare avatar conformi al prompt OOD (capelli ondulati e assenza di occhiali) conseguendo un'accuratezza di attributo dell'89.2% e un FID competitivo pari a 22.48, a fronte di una partizione di addestramento che non conteneva alcuna occorrenza congiunta di tale binomio. Questo traguardo dimostra empiricamente che i meccanismi di SpatialCrossAttention intercalati nella U-Net non agiscono come una memoria associativa statica (che si limiterebbe a recuperare 'collage' di figure già viste), bensì proiettano i vettori lessicali in sottospazi di feature ortogonali. La rete impara a trattare la capigliatura e gli accessori oculari come operatori geometrici disaccoppiati, applicandoli in modo combinatorio sul collettore dei pixel.

Sfide Tecniche Incontrate e Soluzioni Ingegneristiche Adottate: Durante l'iter progettuale sono emerse problematiche di non banale risoluzione:

- *Asimmetria di Gradiente tra Denoiser e Transformer:* Con una U-Net convoluzionale da 24.5M di parametri co-addestrata con un text encoder da soli 2.14M, nelle prime iterazioni la U-Net tendeva a minimizzare la loss basandosi unicamente sul denoise incondizionato, lasciando il Transformer in stallo. L'introduzione di un Linear Warmup su 5 epoche e l'applicazione di gradient clipping disaccoppiato hanno garantito la corretta sincronizzazione dei flussi di ottimizzazione.
- *Divergenza Stocastica ed Esplosione della CFG (Posterizzazione):* L'estrapolazione lineare indotta da un fattore di guida w = 3.5 generava stime provvisorie x■_0 fuori scala rispetto al dominio [-1.0, 1.0]. Nei passaggi successivi del loop inverso, tali anomalie si amplificavano a valanga provocando chiazze bianche e contorni bruciati. Il bloccaggio numerico tramite torch.clamp(x■_0, -1.0, 1.0) ad ogni singolo timestep ha eliminato completamente il fenomeno.
- *Underflow Numerico in Precisione Mista FP16:* L'adozione canonica di costanti additive elevate (es. -1e9) per mascherare i token <PAD> causava valori non definiti (NaN) all'uscita delle softmax a mezza precisione. La criticità è stata superata adottando maschere booleane native e implementando conversioni difensive nei tensori di input.

Raccomandazioni Scientifiche per Sviluppi Futuri: Alla luce delle lezioni apprese, si delineano tre traiettorie evolutive di primario interesse:

1. *Transizione a Latent Diffusion (from-scratch VQ-VAE):* Operare in pixel-space vincola la risoluzione a 64×64. Addestrando preventivamente da zero un autoencoder convoluzionale quantizzato (VQ-VAE) con fattore di downsampling 4×, la diffusione opererebbe su matrici latenti 16×16×4 canali. Ciò abbatterebbe del 75% il consumo di VRAM, permettendo di innalzare la risoluzione finale a 128×128 o 256×256 pixel a parità di budget GPU.
2. *Loss Ausiliaria di Consistenza degli Attributi:* L'obiettivo basato unicamente su MSE tratta ogni pixel in modo uniforme. L'integrazione di una testa classificatrice ausiliaria congelata (Lightweight Attribute Classifier) capace di retropropagare una cross-entropy sui tratti estratti da x■_0 incentiverebbe il modello a risolvere ambiguità minute (es. pigmentazione dell'iride o montature sottili).
3. *Adozione del Rectified Flow / Flow Matching:* La sostituzione delle traiettorie curvilinee stocastiche DDPM con equazioni differenziali ordinarie a trasporto ottimale (Flow Matching) permetterebbe di raddrizzare le traiettorie di denoise, consentendo una generazione fotorealistica in appena 4-8 passi deterministici con drastico abbattimento della latenza d'inferenza.

Considerazioni Conclusive dello Studente: L'esperienza progettuale ha consentito di maturare una visione profonda e non astratta delle complesse dinamiche che governano i modelli generativi a diffusione. Rifiutare l'impiego di librerie prefabbricate e affrontare da zero ogni criticità matematica — dall'omogeneità dello schedule a coseno alla calibrazione della cross-attention e del Classifier-Free Guidance — ha permesso di apprezzare i delicati compromessi tra capacità di generalizzazione, stabilità dei gradienti ed efficienza dei parametri. I risultati empirici conseguiti testimoniano come un'architettura leggera, se rigorosamente ingegnerizzata, sia pienamente capace di disaccoppiare concetti complessi e di sintetizzare contenuti fisionomici inediti con impeccabile coerenza.

Riferimenti Bibliografici

• J. Ho, A. Jain, P. Abbeel, *Denoising Diffusion Probabilistic Models*, Advances in Neural Information Processing Systems (NeurIPS), 2020.

• A. Q. Nichol, P. Dhariwal, *Improved Denoising Diffusion Probabilistic Models*, International Conference on Machine Learning (ICML), 2021.

• T. Salimans, J. Ho, *Progressive Distillation for Fast Sampling of Diffusion Models*, International Conference on Learning Representations (ICLR), 2022.

• J. Song, C. Meng, S. Ermon, *Denoising Diffusion Implicit Models*, International Conference on Learning Representations (ICLR), 2021.

• A. Vaswani, N. Shazeer, N. Parmar, et al., *Attention Is All You Need*, Advances in Neural Information Processing Systems (NeurIPS), 2017.

• Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nicklas, M. Le, *Flow Matching for Generative Modeling*, arXiv:2210.02747, 2022.