POLITECNICO DI BARI

DIPARTIMENTO DI INGEGNERIA ELETTRICA E DELL'INFORMAZIONE

CORSO DI LAUREA MAGISTRALE IN INGEGNERIA INFORMATICA — INSEGNAMENTO DI DEEP LEARNING

Tiny Text-Conditioned Avatar Diffusion from Scratch

Relazione Tecnica di Progettazione, Addestramento e Valutazione Sperimentale

Docente: Prof. Ing. Vito Walter Anelli, Ph.D. | **Candidato:** Studente Magistrale in Ingegneria Informatica | **Codice Prova:** 2026 VI

Sommario Discorsivo: *Il presente lavoro documenta la progettazione, l'implementazione rigorosa, l'addestramento e la disamina sperimentale di un'architettura generativa stocastica di diffusione nello spazio dei pixel, sviluppata interamente from-scratch senza alcun ricorso a pesi pregressi, modelli linguistici pre-addestrati o librerie black-box di terze parti. L'indagine scientifica persegue il duplice obiettivo di verificare la fattibilità di un sistema text-to-image compatto conforme a rigidi vincoli computazionali e di vagliarne la generalizzazione composizionale out-of-distribution (OOD) su combinazioni di attributi fisionomici deliberatamente omesse nella fase di apprendimento. L'elaborato, redatto in aderenza alle consegne formali, espone dettagliatamente l'approccio ingegneristico adottato — dal preprocessing deterministico dei dati al co-addestramento della U-Net con il Transformer linguistico sino alle metriche di benchmarking — e approfondisce criticamente le prestazioni del modello, le sfide affrontate nella stabilizzazione dei gradienti e le traiettorie di evoluzione futura.*

A Report Documenting the Detailed Approach, Including Data Preprocessing, the Model Training, and Evaluation Results

1. Data Preprocessing e Costruzione Rigorosa del Dataset

La costruzione della pipeline di preprocessing ha richiesto un controllo meticoloso dei flussi informativi al fine di rispettare la duplice prescrizione dell'assegnamento: garantire la perfetta riproducibilità matematica dell'esperimento e prevenire categoricamente qualsiasi fenomeno di data leakage statistico tra le diverse partizioni del dataset. Come corpus visivo di riferimento è stato adottato il Google Cartoon Set nella sua formulazione estesa a centomila campioni bidimensionali, archiviati alla risoluzione nativa in formato JPEG. Ai campioni iconici si affiancano i relativi metadati strutturati, raccolti nel file tabellare dei tratti distintivi in cui a ogni avatar corrispondono indici categorici discreti che ne codificano la conformazione del volto, la capigliatura, la pigmentazione cutanea, le fattezze oculari, la presenza di occhiali e la barba.

L'elaborazione delle immagini prevede il caricamento RGB tramite Pillow e il conseguente ridimensionamento alla risoluzione canonica di sessantaquattro per sessantaquattro pixel mediante interpolazione bilineare. I tensori numerici risultanti, originariamente definiti nell'intervallo continuo compreso tra zero e uno, subiscono una normalizzazione simmetrica che ne trasla il dominio tra meno uno e più uno, applicando valori di media e deviazione standard entrambi fissati a zero virgola cinque per ciascun canale cromatico. Tale trasformazione risponde a una precisa motivazione stocastica: nelle formulazioni canoniche dei modelli di diffusione con predizione di rumore o di velocità, il segnale visivo deve essere centrato nell'origine e vincolato a una varianza unitaria per integrarsi in modo

stabile con il rumore gaussiano standard iniettato lungo la traiettoria di forward noising.

Sul versante della rappresentazione testuale, il modulo di generazione delle didascalie trasforma i codici interi dei metadati in frasi descrittive in linguaggio naturale privo di numeri o identificatori spuri. Attraverso una mappatura semantica esplicita, ogni chiave numerica viene tradotta in un attributo verbale leggibile: a titolo esemplificativo, il codice numerico novantotto associato ai capelli viene convertito nella parola inglese corrispondente a ondulato, l'indice undici degli occhiali viene tradotto nell'espressione che ne attesta l'assenza, mentre i codici della pelle vengono rimappati su gradazioni semantiche quali porcellana, chiara o scura. Il template deterministico strutturato adotta la forma canonica di un avatar con una determinata pelle, capigliatura, occhi, occhiali e barba, applicando una sanitizzazione della punteggiatura e degli spazi multipli così da produrre sequenze lessicali omogenee.

La costruzione del vocabolario e del tokenizer costituisce uno dei punti cardine della metodologia strictly from-scratch. Per rispettare il vincolo di isolamento epistemico, la scansione lessicale e l'estrazione delle frequenze dei token sono state eseguite unicamente sulle didascalie appartenenti alla partizione di addestramento, escludendo totalmente i campioni di validazione e di test. Il vocabolario riserva in maniera deterministica e immutabile i primi quattro indici interi ai token speciali di sistema: il valore zero corrisponde al padding, l'indice uno rappresenta i token sconosciuti fuori vocabolario, l'indice due funge da start of sequence e l'indice tre delimita l'end of sequence. L'inserimento dei vocaboli lessicali effettivi avviene a partire dall'indice intero quattro, azzerando ogni rischio di sovrascrittura accidentale dei simboli di controllo. L'universo lessicale risultante conta esattamente centoquarantanove token univoci, sufficienti a coprire integralmente la varietà morfologica e cromatica degli avatar. La lunghezza massima delle sequenze tokenizzate è stata fissata a venti elementi: le frasi di lunghezza inferiore vengono completate a destra con token di padding, mentre le eventuali eccedenze subiscono un troncamento deterministico.

Per indagare sperimentalmente la capacità di generalizzazione composizionale, il partizionamento del dataset è stato strutturato a quattro vie fondandosi sulla separazione mirata di combinazioni congiunte di attributi piuttosto che su una suddivisione puramente stocastica. Nello specifico, è stata definita una coppia di attributi bloccata e trattenuta dall'addestramento, costituita dalla co-presenza di capelli ondulati e assenza di occhiali. Entrambi i tratti distintivi compaiono regolarmente nel training set presi singolarmente — i capelli ondulati associati a svariate montature e l'assenza di occhiali combinata con capigliature lisce o ricce — ma la loro intersezione simultanea è stata completamente estromessa dalla fase di ottimizzazione. Su un totale di centomila campioni, la partizione di addestramento conta settantanovemila seicentoquarantaquattro immagini, la frazione di validazione ne assorbe novemilanovecentocinquantaquattro e la partizione di test ordinario in-distribution ne comprende parimenti novemilanovecentocinquantaquattro, pari rispettivamente all'ottanta, dieci e dieci percento della massa in-distribution. Il sottoinsieme di test composizionale out-of-distribution raccoglie la totalità dei quattrocentocinquantotto avatar che esibiscono la combinazione congiunta trattenuta. Gli indici di ripartizione sono stati serializzati stabilmente su disco, garantendo la riproducibilità esatta dell'intera suddivisione.

2. Architettura del Modello e Processo di Addestramento Strictly From Scratch

In conformità categorica alle specifiche didattiche, l'intera infrastruttura computazionale è stata sviluppata senza alcuna dipendenza da checkpoint pregressi, modelli linguistici esterni o pacchetti di generazione pronti all'uso. Non sono stati importati né invocati moduli da Diffusers, né sono stati adoperati encoder pre-addestrati quali CLIP, BERT o T5, né tantomeno autoencoder variazionali latenti o vettori lessicali pre-calcolati. Il sistema opera in modo puro e diretto nello spazio dei pixel, elaborando tensori quadridimensionali di forma pari a batch per tre canali cromatici per sessantaquattro per sessantaquattro pixel.

L'elaborazione del condizionamento testuale è demandata a un FullTextEncoder realizzato da zero come un Transformer compatto a quattro strati. Ciascun layer integra un modulo di multi-head self-attention a quattro teste parallele con dimensione del modello pari a duecentocinquantasei e ampiezza del feed-forward interno pari a cinquecentododici unità, corredato da connessioni residue e strati di layer normalization scritti manualmente. La codifica posizionale adotta le formulazioni sinusoidali canoniche registrate come costanti di buffer non differenziabili, mentre la matrice di incorporamento converte gli indici lessicali in rappresentazioni dense scalate per

la radice quadrata della dimensione nascosta. L'encoder testuale impegna complessivamente due milioni centoquarantaduemila quattrocentottantadue parametri allenabili, fornendo in uscita una matrice di contesto avente venti token per duecentocinquantasei dimensioni per ciascun campione del batch.

Il denoiser visivo poggia su un'architettura U-Net parametrizzata su novantasei canali di base, operante su tre scale spaziali successive: sessantaquattro per sessantaquattro, trentadue per trentadue e sedici per sedici pixel nel collo di bottiglia. La rete incorpora blocchi a doppia convoluzione con normalizzazione a gruppi e non-linearità SiLU, integrati con proiezioni sinusoidali del tempo di diffusione espanse attraverso un perceptron multistrato a due livelli fino a duecentocinquantasei dimensioni. Nei livelli di risoluzione intermedia e nel bottleneck sono intercalati moduli di spatial self-attention e di spatial cross-attention. Questi ultimi consentono ai tensori bidimensionali delle feature visive di interrogare le proiezioni di chiavi e valori generate dal contesto testuale, orientando l'evoluzione dei gradienti verso la configurazione fisionomica voluta. Nel ramo di risalita, il ripristino della risoluzione spaziale avviene tramite sovracampionamento bilineare seguito dalla concatenazione delle skip connections provenienti dal percorso di discesa. La U-Net totalizza ventiquattro milioni cinquecentodiciannovemila settecentonovantacinque parametri, conducendo l'intero apparato neurale a un footprint complessivo di ventisei milioni seicentosessantaduemila duecentosettantasette parametri, pienamente compatibile con l'inviluppo dimensionale leggero stabilito per una GPU NVIDIA T4.

La dinamica stocastica è governata da uno scheduler a mille passi discreti basato sulla formulazione a coseno introdotta da Nichol e Dhariwal, avente parametro di offset pari a zero virgola zero zero otto e vincolo superiore sulla varianza fissato a zero virgola novecentonovantanove per scongiurare singolarità nei pressi dell'istante terminale. Il processo di forward noising sfrutta la proprietà analitica della somma gaussiana per perturbare l'immagine pulita direttamente al timestep desiderato mediante una singola operazione vettorializzata. Sul piano dell'obiettivo di ottimizzazione, anziché ricorrere alla predizione diretta del rumore epsilon, è stata implementata la parametrizzazione a velocità nota come v-prediction, formalizzata da Salimans e Ho. Definendo il bersaglio neurale come combinazione lineare ponderata del rumore iniettato e del segnale pulito, la funzione di perdita dell'errore quadratico medio tra la velocità predetta dalla U-Net e la velocità target garantisce una stabilità numerica superiore lungo l'intera traiettoria, mitigando le asimmetrie di gradiente agli estremi dell'orizzonte temporale.

L'addestramento contempla l'impiego della tecnica Classifier-Free Guidance. Durante la propagazione in avanti, con una frequenza di dropout pari al dieci percento, i token descrittivi vengono sostituiti dal contesto incondizionato generato mediante sequenze di soli token di padding, istruendo la rete a modellare sia la distribuzione condizionata sia la componente marginale incondizionata all'interno del medesimo set di pesi. La configurazione dell'ottimizzatore AdamW prevede un decadimento del peso pari a uno per dieci alla meno quattro applicato selettivamente alle matrici con dimensionalità pari o superiore a due, mentre per tutti i parametri monodimensionali — compresi i termini di bias e i coefficienti di scala e traslazione delle normalizzazioni — il weight decay è azzerato per evitare una regolarizzazione dannosa. La dinamica del tasso di apprendimento prevede una fase iniziale di riscaldamento lineare della durata di cinque epoche, indispensabile per stabilizzare il text encoder prima di raggiungere il valore di regime pari a due per dieci alla meno cinque, seguito da un decadimento continuo secondo una curva a coseno.

A salvaguardia della convergenza sono stati introdotti due accorgimenti tecnici determinanti: il ritaglio disaccoppiato dei gradienti, applicato in modo indipendente alla U-Net e al text encoder con norma euclidea massima pari a uno, e l'impiego della precisione mista automatica con scaler dinamico per prevenire fenomeni di underflow nei calcoli a sedici bit. Inoltre, per contrastare le oscillazioni ad alta frequenza e il rischio di collasso modale, è stato mantenuto un modello ombra aggiornato mediante Exponential Moving Average con fattore di decadimento pari a zero virgola novecentonovantanove, i cui pesi consolidati sono stati impiegati in via prioritaria per l'inferenza e la stima delle metriche.

3. Risultati della Valutazione Sperimentale e Benchmarking

La quantificazione sperimentale delle prestazioni del modello è stata condotta eseguendo i moduli dedicati di valutazione e inferenza sul checkpoint salvato al termine della sessantacinquesima epoca di addestramento, avvalendosi dell'accelerazione hardware di una scheda grafica dedicata per ambiente laptop. L'analisi del consumo di risorse computazionali evidenzia un'occupazione di picco della memoria VRAM pari a settecentosettantotto virgola settanta megabyte durante la generazione dei batch, valore ampiamente inferiore alla soglia di un gigabyte che dimostra l'estrema efficienza e leggerezza dell'architettura implementata. La latenza temporale del singolo passaggio forward della U-Net si attesta su zero virgola duecentotrentotto secondi, consentendo una rapida iterazione nei cicli di calcolo.

Sul fronte della rapidità di campionamento, l'indagine mette in luce un contrasto netto tra la traiettoria stocastica standard DDPM e il campionamento deterministico accelerato DDIM. L'esecuzione del reverse loop completo su mille passi di denoisazione richiede un tempo medio di quarantanove virgola cinquantuno secondi per la sintesi di un singolo avatar. Al contrario, l'impiego dello schema DDIM riduce la traiettoria a cinquanta passi temporali, abbattendo la latenza a un secondo e undici centesimi per immagine, con un'ulteriore contrazione a zero virgola novantanove secondi nel caso di una discretizzazione a venti passi. Questa accelerazione di circa quarantacinque volte rispetto al campionamento completo avviene senza alcuna degradazione visibile nella nitidezza dei contorni o nella fedeltà ai tratti semantici, rendendo il modello adatto all'impiego interattivo.

La valutazione della qualità distribuzionale e dell'allineamento statistico è stata formalizzata calcolando la Fréchet Inception Distance e la Kernel Inception Distance su campioni generati dalle partizioni di test, adottando la dimensionalità a sessantaquattro feature di Inception con ri-normalizzazione preventiva rigorosa nell'intervallo continuo compreso tra zero e uno. Sulla partizione di test ordinario in-distribution, composta da quasi diecimila immagini con tratti combinati conformi alle frequenze di training, il generatore consegue un valore di FID pari a due virgola zero centonovantatré e un valore medio di KID pari a zero virgola zero cinquantatré con deviazione standard trascurabile. Valutando il modello sulla partizione di test out-of-distribution composizionale — costituita dai quattrocentocinquantotto esemplari che esibiscono la combinazione trattenuta di capelli ondulati e assenza di occhiali — il valore di FID registrato risulta pari a uno virgola quattrocentocinquantaquattro, mentre il KID medio si attesta su zero virgola zero settecentodiciotto.

Il riscontro numerico del FID sulla partizione out-of-distribution, perfettamente allineato e addirittura lievemente inferiore a quello ordinario, fornisce una prova tangibile della robustezza geometrica del modello: la U-Net non collassa su artefatti caotici né genera strutture degenerate quando deve fondere attributi mai osservati congiuntamente. L'incremento del valore medio di KID da zero virgola zero cinquantatré a zero virgola zero settecentodiciotto, corrispondente a un aumento percentuale nell'ordine del trentacinque percento, riflette coerentemente la maggiore incertezza probabilistica del modello nel comporre matrici di feature visive reciprocamente inedite, manifestandosi sul piano visivo in lievi irregolarità di micro-contrasto che tuttavia non inficiano minimamente la plausibilità complessiva del volto sintetizzato.

La variabilità stocastica della generazione a parità di condizionamento linguistico è stata quantificata mediante la distanza percettiva Pairwise LPIPS calcolata su backbone VGG tra avatar generati con semi casuali differenti compresi tra mille e milletre. Su un primo prompt caratterizzato da carnagione porcellana, capelli corti, occhi azzurri, occhiali tondi e assenza di barba, la diversità percettiva media tra le coppie di seed è risultata pari a zero virgola millenovecentottantuno. Su un secondo prompt, raffigurante pelle scura, capelli mossi, occhi scuri, assenza di occhiali e barba folta, la dispersione sale a zero virgola duemilacinquecentodieci. La diversità media complessiva calcolata sull'insieme dei test è pari a zero virgola duemiladuecentoquarantacinque. Questo risultato attesta che la guida del testo indirizza saldamente l'identità semantica senza soffocare la naturale eterogeneità morfologica del processo diffusivo, permettendo al generatore di produrre declinazioni fisionomiche differenziate e non banali.

Analysis and Discussion of the Model’s Performance, Challenges Faced, and Recommendations for Improvement

1. Analisi e Discussione Approfondita delle Prestazioni del Modello

La risposta alla domanda scientifica fondamentale posta dall'assegnamento — ovvero se un modello di diffusione estremamente compatto con denoiser e text encoder entrambi addestrati da zero possa generalizzare a combinazioni di attributi non osservate congiuntamente durante l'addestramento — è affermativa, e trova riscontro sia nei riscontri numerici sia nell'ispezione morfologica degli avatar sintetizzati. Il successo della generalizzazione composizionale risiede nell'interazione virtuosa tra due proprietà strutturali della pipeline: l'ortogonalità funzionale del meccanismo di spatial cross-attention e il forte bias induttivo geometrico intrinseco alle convoluzioni della U-Net.

All'interno dei blocchi di cross-attention, i token lessicali vengono proiettati negli spazi lineari di chiavi e valori mediante matrici di peso apprese congiuntamente. Poiché le teste di attenzione calcolano similarità scalari indipendenti per ciascun vettore di contesto, la presenza del token relativo ai capelli mossi attiva selettivamente la componente tensoriale deputata alla capigliatura senza costringere le rimanenti teste ad attivare configurazioni correlate. In parallelo, il bias induttivo convoluzionale impone una separazione topologica naturale: i pattern visivi legati alla fronte e alla chioma risiedono nella frazione superiore delle mappe di attivazione, mentre le feature associate al naso, agli occhi e agli occhiali si concentrano nella fascia mediana. Questa compartimentazione spaziale fa sì che la U-Net non apprenda associazioni spurie rigide, consentendo alle due feature di coesistere in modo coerente nello stesso output.

Un elemento essenziale che governa le prestazioni generative risiede nella sensibilità alla scala di Classifier-Free Guidance. Durante la sperimentazione è emerso un comportamento fortemente correlato al valore del moltiplicatore scalare w. Impiegando fattori di guida inferiori a due, il modello manifesta una regressione verso la distribuzione a priori, tendendo a ignorare parzialmente gli attributi rari in favore delle configurazioni più frequenti nel dataset. Al contrario, l'intervallo compreso tra due virgola cinque e tre virgola cinque realizza il compromesso ideale: la forza del condizionamento orienta in modo impeccabile sia la presenza dei capelli mossi sia l'assenza della montatura degli occhiali, preservando sfumature e morbidezza nei contorni del viso. Se la guida viene spinta oltre il valore cinque, l'estrapolazione lineare della velocità finisce per sovraccaricare le ampiezze dei gradienti, provocando un'ipersaturazione cromatica e un contrasto innaturale lungo i bordi delle campiture, effetto collaterale della dispersione nello spazio nativo dei pixel in assenza di un collettore latente compresso.

2. Sfide Ingegneristiche Affrontate e Soluzioni Adottate nel Codice

La realizzazione da zero dell'intero sistema ha posto molteplici sfide di natura teorica e implementativa, che hanno richiesto interventi mirati sull'architettura del codice e sulla dinamica dei gradienti per assicurare la stabilità numerica e la qualità del campionamento.

La prima grande difficoltà ha riguardato l'instabilità nel co-addestramento simultaneo della U-Net e del text encoder. Data la marcata asimmetria dimensionale tra la rete di denoisazione, forte di oltre ventiquattro milioni di parametri, e il trasformatore linguistico, limitato a circa due milioni, nelle fasi iniziali del training la U-Net tendeva a minimizzare la perdita di velocità concentrandosi esclusivamente sulle statistiche visive non condizionate, lasciando il text encoder in uno stato di convergenza ritardata. Per risolvere questa disarmonia è stata concepita una strategia di ottimizzazione a due stadi: nei primi cinque cicli di epoca, un riscaldamento lineare ha protetto il text encoder da aggiornamenti distruttivi; parallelamente, l'applicazione del gradient clipping disaccoppiato a soglia unitaria su ciascun modulo e la disattivazione del decadimento del peso per i parametri monodimensionali hanno impedito ai gradienti convoluzionali di soffocare l'evoluzione delle matrici di attenzione testuale.

Una seconda criticità severa si è manifestata sotto forma di divergenza delle traiettorie inverse durante il campionamento con Classifier-Free Guidance. L'estrapolazione vettoriale della velocità, pur garantendo un forte allineamento al testo, produceva valori intermedi che spingevano la stima analitica del segnale pulito al di fuori dei limiti ammissibili dell'intervallo simmetrico tra meno uno e più uno. Nei passaggi temporali successivi questo

sforamento provocava un accumulo di errori a cascata, culminando in gravi artefatti di posterizzazione e chiazze di pixel bianchi incontrollati. La soluzione ha richiesto l'integrazione del dynamic range clipping direttamente nel ciclo di reverse sampling: a ogni passo temporale, la stima provvisoria dell'immagine denoisata calcolata a partire dalla velocità predetta viene forzata numericamente nell'intervallo tra meno uno e più uno prima di procedere alla ponderazione stocastica dello stato precedente. Questo vincolo ha eradicato ogni residuo di posterizzazione, restituendo campiture solide e uniformi.

La terza sfida ha riguardato l'elevata varianza stocastica intrinseca ai modelli di diffusione nello spazio dei pixel, che manifestavano un'alternanza della fedeltà fisionomica tra epoche successive dovuta a fluttuazioni dei pesi attorno ai minimi locali. L'introduzione della media mobile esponenziale con fattore di decadimento zero virgola novecentonovantanove ha consentito di disaccoppiare la fase esplorativa dell'ottimizzatore dalla stabilità strutturale del denoiser finale. I pesi consolidati dell'AveragedModel preservano la nitidezza geometrica del volto e la coerenza cromatica anche nei passaggi temporali a elevata componente di rumore.

Infine, la gestione dei contesti a precisione mista con rappresentazione FP16 ha fatto emergere criticità di underflow numerico durante il calcolo delle maschere di attenzione. L'assegnazione convenzionale di costanti negative elevate come meno dieci alla nona nei token di padding provocava la comparsa di valori non definiti (NaN) all'uscita delle funzioni softmax, compromettendo l'integrità dei gradienti. La problematica è stata sanata sostituendo le matrici additive con maschere booleane native compatibili con i kernel ottimizzati e corredando i flussi di calcolo con chiamate difensive di sanitizzazione numerica.

3. Raccomandazioni per il Miglioramento Futuro

Alla luce dell'esperienza progettuale maturata e delle evidenze empiriche raccolte, si delineano tre direttrici primarie di sviluppo e ottimizzazione per future evoluzioni del sistema.

In primo luogo, si raccomanda l'adozione di un'architettura latente compatta, basata sull'addestramento strictly from-scratch di un Vector Quantized Variational Autoencoder (VQ-VAE) o di un autoencoder convoluzionale poco profondo. Attualmente, l'esecuzione della spatial cross-attention direttamente sulla griglia dei pixel a piena risoluzione comporta un onere computazionale che scala quadraticamente con le dimensioni spaziali della mappa di feature. Comprimendo preventivamente le immagini in uno spazio latente compatto avente risoluzione sedici per sedici con quattro canali latenti, si otterrebbe un abbattimento significativo del footprint di memoria e dei tempi di inferenza, consentendo di reinvestire il budget parametrico nell'aumento della profondità della U-Net o nell'innalzamento della risoluzione finale a centoventotto per centoventotto pixel senza violare le soglie hardware.

Una seconda raccomandazione riguarda l'integrazione di una perdita ausiliaria di consistenza degli attributi calcolata mediante un classificatore multi-etichetta ausiliario. Sebbene la funzione di perdita basata sull'errore quadratico medio della velocità supervisioni efficacemente la convergenza globale, essa tratta ogni deviazione di pixel in modo indifferenziato. L'impiego di una testa di classificazione congelata capace di calcolare una perdita di cross-entropy sulla stima dell'immagine denoisata x zero a timestep intermedi consentirebbe di retro-propagare gradienti di alto livello esplicitamente legati all'esattezza cromatica dell'iride, alla presenza della barba o alla tipologia della montatura, incrementando ulteriormente l'aderenza semantica nei dettagli fisionomici più minuti.

Infine, sul versante della formulazione matematica del processo stocastico, si suggerisce la transizione dal framework DDPM con equazioni differenziali stocastiche curvilinee verso il paradigma del Rectified Flow e del Flow Matching con trasporto ottimale, teorizzato da Lipman e collaboratori. Formulando la dinamica generativa attraverso equazioni differenziali ordinarie con traiettorie lineari a velocità costante tra il rumore gaussiano e la distribuzione degli avatar, diverrebbe possibile sintetizzare immagini di qualità impeccabile in appena quattro o otto passi di integrazione numerica deterministica, rendendo l'inferenza quasi istantanea e superando i limiti di approssimazione intrinseci agli schemi DDIM discretizzati.

Considerazioni Conclusive dello Studente

In conclusione, l'attività svolta ha permesso di consolidare approfondite competenze pratiche e metodologiche sulle dinamiche dei modelli generativi basati sulla diffusione stocastica. La sfida di implementare ogni componente strictly from-scratch — dalla tokenizzazione alla U-Net con cross-attention e allo scheduler v-prediction — ha offerto una comprensione trasparente dei compromessi architetturali necessari per coniugare stabilità di ottimizzazione, leggerezza computazionale e capacità di astrazione semantica. I risultati ottenuti certificano la piena validità dell'approccio e confermano come anche un'architettura compatta, se accuratamente regolarizzata, sia pienamente in grado di disaccoppiare concetti complessi e generalizzare con successo verso combinazioni composizionali inedite.

Riferimenti Bibliografici Formativi

- J. Ho, A. Jain, P. Abbeel, *Denoising Diffusion Probabilistic Models*, Advances in Neural Information Processing Systems (NeurIPS), 2020.
- A. Q. Nichol, P. Dhariwal, *Improved Denoising Diffusion Probabilistic Models*, International Conference on Machine Learning (ICML), 2021.
- T. Salimans, J. Ho, *Progressive Distillation for Fast Sampling of Diffusion Models*, International Conference on Learning Representations (ICLR), 2022.
- J. Song, C. Meng, S. Ermon, *Denoising Diffusion Implicit Models*, International Conference on Learning Representations (ICLR), 2021.
- Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nicklas, M. Le, *Flow Matching for Generative Modeling*, arXiv:2210.02747, 2022.
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, I. Polosukhin, *Attention Is All You Need*, NeurIPS, 2017.